

# Statistique descriptive avec R

## TP 3

Téléchargez au format CSV l'historique d'un portefeuille investi sur le SP500 :  
<https://curvo.eu/backtest/fr/indice/sp-500?currency=eur#graphique>.

1. Importez les données et mettez la première colonne au format **Date** au 1er janvier, vous spécifierez le type des données à l'importation.
2. Ajoutez la colonne **Perf** définie comme la performance mensuelle du SP500 :

$$\text{Perf}_t := \frac{\text{SP500}_t - \text{SP500}_{t-1}}{\text{SP500}_{t-1}}, \quad t \geq 2.$$

Mettez **NA** pour le premier mois où ce n'est pas calculable.

3. Affichez l'histogramme des performances.
4. Définissez une variable **Perf** : le vecteur des performances calculées sans la donnée manquante, puis définissez une variable **batons** : une séquence qui démarre de la valeur minimale de vos données arrondie au centième et s'achève à la valeur maximale arrondie au centième, avec un pas d'un centième.
5. Affichez l'histogramme en utilisant un pas d'un centième pour les bâtons.
6. Calculez la moyenne et l'écart-type des performances.
7. Sur votre histogramme, affichez la densité gaussienne avec la moyenne et la variance empiriques calculées. Pour comparer l'histogramme à la densité, il faut ajouter l'argument **freq=FALSE** à celui-ci.
8. La fonction **density** permet d'obtenir la densité empirique par méthode de noyaux définie par :

$$\hat{f}(x) := \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - x_i}{h}\right), \quad x \in \mathbb{R},$$

où  $(x_i)_{1 \leq i \leq n}$  est l'échantillon observé,  $h$  est la *fenêtre* (**R** la calculera de manière optimale) et  $K$  est une densité centrée réduite (par défaut, **R** utilise la loi normale).

En utilisant les paramètres par défaut de **density**, affichez la densité empirique des performances et comparez à celle de la loi normale.

9. Nous allons tester si les données sont normales. Nous allons utiliser le test de Jarque-Bera. Calculez le skewness et le kurtosis et commentez par rapport à la loi normale.

10. Le test de Jarque-Bera repose sur le résultat de convergence suivant : si les données  $(X_i)_{1 \leq i \leq n}$  sont normales et i.i.d.,

$$JB_n := n \left( \frac{S_n^2}{6} + \frac{(K_n - 3)^2}{24} \right) \xrightarrow{n \rightarrow +\infty} \chi_2^2,$$

où  $S_n$  est le skewness des données et  $K_n$  en est le kurtosis. Calculez  $JB_n$ .

11. La p-valeur est la probabilité, sous l'hypothèse nulle  $\{H_0 : \text{Les performances sont gaussiennes}\}$ , d'obtenir une statistique de test au moins aussi extrême que celle observée, dans la queue de la distribution. Ici, pour le test de Jarque-Bera, elle correspond à  $\mathbb{P}(\chi_2^2 > JB_n)$  où  $JB_n$  est la valeur du test observée empiriquement. Calculez la p-valeur et concluez.

12. Mettez le calcul du test dans une fonction de [R](#).